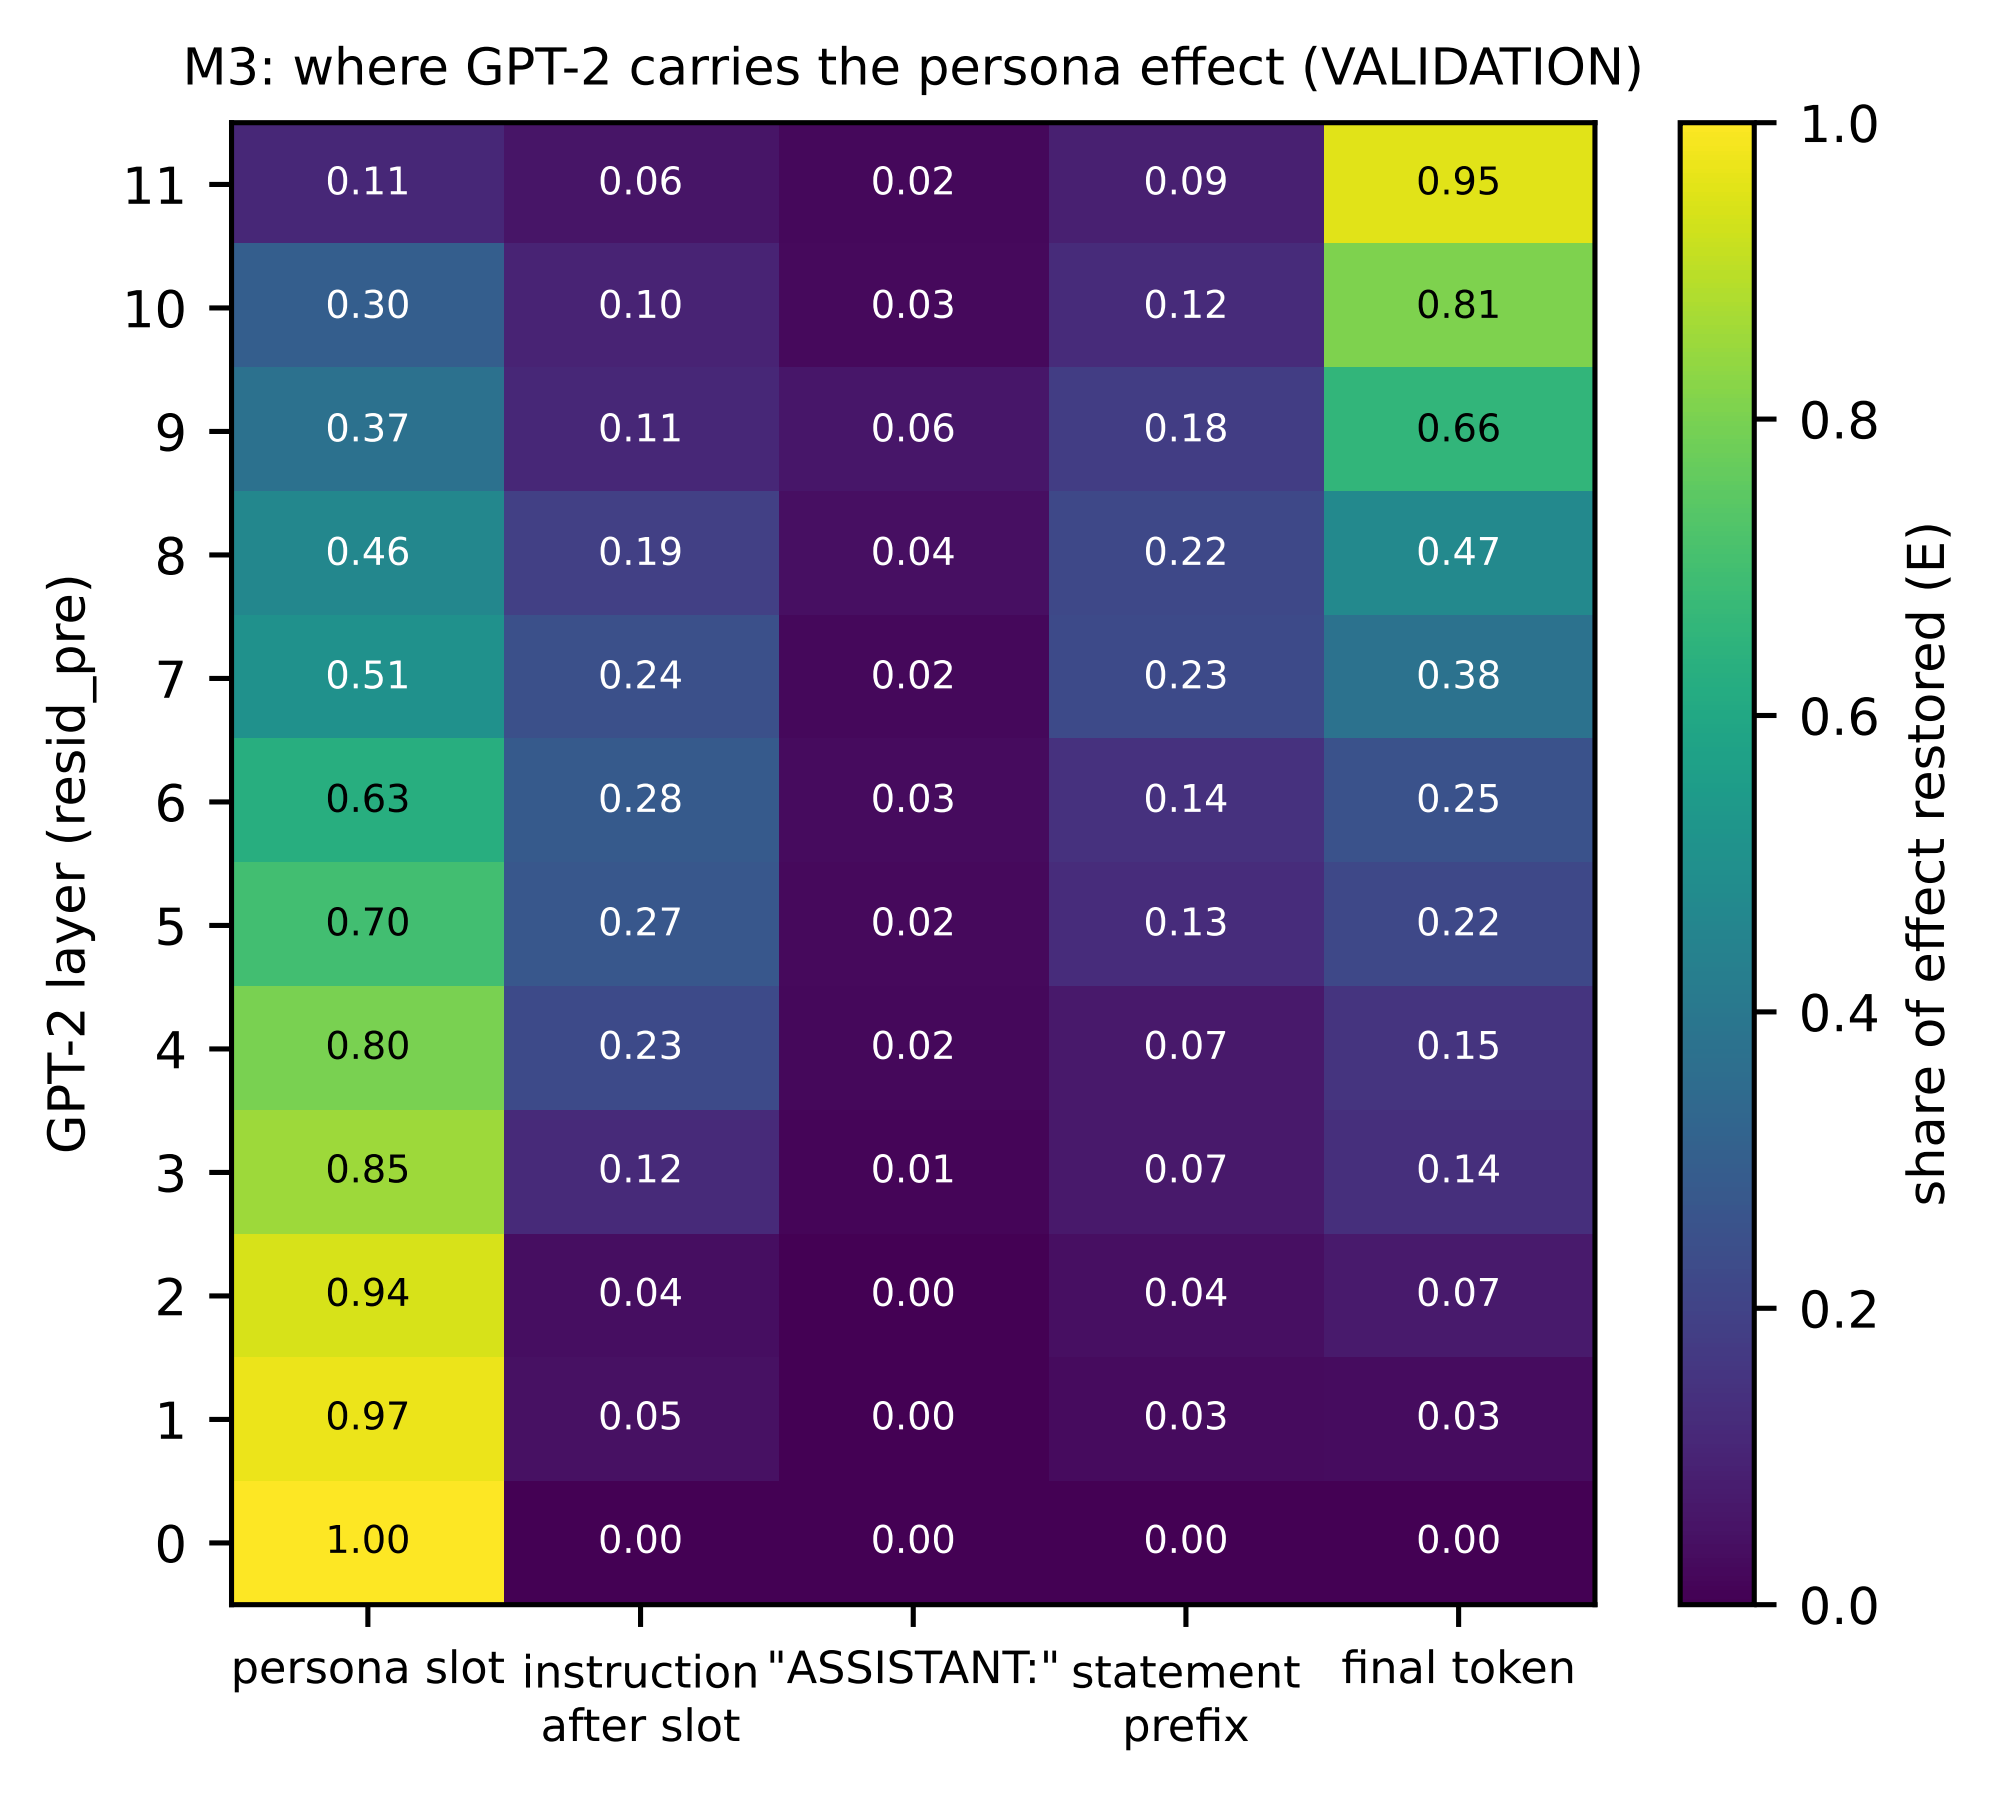
M3: where GPT-2 carries the persona effect (VALIDATION)
GPT-2 layer (resid_pre)
11
10
9
8
7
6
5
4
3
2
1
0
0.11 0.06 0.02 0.09 0.95
0.30 0.10 0.03 0.12 0.81
0.37 0.11 0.06 0.18 0.66
0.46 0.19 0.04 0.22 0.47
0.51 0.24 0.02 0.23 0.38
0.63 0.28 0.03 0.14 0.25
0.70 0.27 0.02 0.13 0.22
0.80 0.23 0.02 0.07 0.15
0.85 0.12 0.01 0.07 0.14
0.94 0.04 0.00 0.04 0.07
0.97 0.05 0.00 0.03 0.03
1.00 0.00 0.00 0.00 0.00
persona slot
instruction after slot
"ASSISTANT:"
statement prefix
final token
share of effect restored (E)
1.0
0.8
0.6
0.4
0.2
0.0